Desarrollo de un Gemelo Digital Dual-Platform para la Estimación de RUL en Motores Turbofan utilizando NASA C-MAPSS

Nicolás García García
Facultad de Ingeniería
Pontificia Universidad Javeriana
Bogotá, Colombia

***Abstract*—Este trabajo presenta el desarrollo e implementación de un Gemelo Digital orientado al monitoreo y predicción de la Vida Útil Remanente (RUL, por sus siglas en inglés) en motores turbofan aeronáuticos, empleando el conjunto de datos C-MAPSS FD001 de la NASA. La metodología abarca el preprocesamiento de series temporales telemétricas, la eliminación de variables sin varianza y la delimitación de la variable objetivo. Mediante un modelo de regresión basado en *Random Forest*, se alcanzó una precisión con un RMSE de 17.07 y un MAE de 12.09 ciclos. Asimismo, se integró una arquitectura *Dual-Platform* constituida por Power BI para el soporte analítico relacional y Python-Streamlit para el despliegue interactivo en tiempo real.**

***Index Terms*—Gemelo Digital, RUL, NASA C-MAPSS, Random Forest, Power BI, Streamlit, Mantenimiento Predictivo.**

I. Introducción

El mantenimiento predictivo en la industria aeronáutica ha evolucionado hacia esquemas basados en la gestión de salud y pronóstico (PHM, *Prognostics and Health Management*) [1]. La estimación precisa de la Vida Útil Remanente (*Remaining Useful Life*, RUL) de componentes críticos, como los motores turbofan, resulta fundamental para prevenir fallas catastróficas en vuelo, optimizar las rutinas de inspección y reducir los costos operativos asociados a paradas no programadas [2].

En este contexto, el concepto de *Gemelo Digital* (*Digital Twin*) surge como un paradigma clave al sincronizar modelos de simulación y de aprendizaje automático con los datos operativos reales recopilados por sistemas de telemetría [2]. A pesar de los avances en técnicas de regresión avanzadas, persisten desafíos para integrar estos modelos predictivos dentro de plataformas analíticas accesibles tanto para la toma de decisiones estratégicas como para la supervisión operativa interactiva.

Este proyecto aborda dicha brecha mediante el desarrollo de una arquitectura *Dual-Platform* aplicada al conjunto de datos C-MAPSS (FD001) de la NASA. La propuesta combina la robustez de un modelo predictivo basado en *Random Forest* con dos capas de visualización: una capa analítica estructurada en Power BI (mediante un modelo de datos *Star Schema*) y una interfaz web interactiva desarrollada en Python con Streamlit y Plotly.

II. Metodología y Preprocesamiento de Datos

El desarrollo del Gemelo Digital se fundamenta en el subconjunto de datos FD001 del simulador C-MAPSS (*Commercial Modular Aero-Propulsion System Simulation*) de la NASA [1]. Dicho dataset contiene 100 trayectorias de degradación para entrenamiento y 100 para prueba, bajo condiciones operacionales constantes y un único modo de falla ubicado en el compresor de alta presión (HPC).

A. Filtrado de Sensores sin Varianza

El dataset original recopila la información telemétrica de 21 sensores. Se realizó un análisis de varianza nula para identificar variables constantes que no aportan capacidad discriminativa al algoritmo de aprendizaje [3]. Los sensores $S_1, S_5, S_6, S_{10}, S_{16}, S_{18}$ y S_{19} presentaron una desviación estándar nula ($\sigma = 0$), por lo cual fueron eliminados del espacio de características, reduciendo la dimensión de entrada a 14 sensores activos.

B. Modelado de la Variable Objetivo (RUL)

Siguiendo las mejores prácticas en el diagnóstico de turbomáquinas [4], se fijó un límite máximo para la variable de respuesta de $RUL_{max} = 125$ ciclos. Esta transformación por tramos (*piecewise linear target*) previene que el modelo asigne valores de RUL excesivamente altos durante las primeras etapas de operación, donde el componente se encuentra en estado óptimo y no presenta degradación apreciable.

C. Arquitectura del Modelo de Regresión

Se entrenó un modelo de regresión basado en *Random Forest* [5] por su capacidad para manejar no linealidades complejas y su alta resistencia al sobreajuste. La optimización del modelo se evaluó mediante la raíz del error cuadrático medio ($RMSE$) y el error absoluto medio (MAE), expresados como:

$$RMSE = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(RUL_{real,i} - RUL_{pred,i})^2} \quad (1)$$

$$MAE = \frac{1}{N}\sum_{i=1}^{N}|RUL_{real,i} - RUL_{pred,i}| \quad (2)$$

El modelo final alcanzó un desempeño de $RMSE = 17.07$ y $MAE = 12.09$ ciclos sobre el conjunto de prueba.

III. Resultados y Discusión de la Arquitectura Dual-Platform

El Gemelo Digital articulado integra dos plataformas complementarias para abordar el monitoreo en diferentes niveles organizacionales de la aviación.

A. Capa Analítica Relacional (Power BI)

Como se observa en el Diagrama Entidad-Relación de la Fig. 1, la capa de inteligencia de negocios está estructurada mediante un modelo en estrella (*Star Schema*). La tabla central de dimensiones `Dim_Engine` vincula las lecturas de telemetría de sensores (`Fact_Sensor_Readings`) con las estimaciones generadas por la inteligencia artificial (`Predicciones_RUL_IA`). Esta arquitectura relacional habilita la agregación mediante medidas DAX avanzadas, permitiendo calcular indicadores de salud global a nivel de flota aeronáutica.

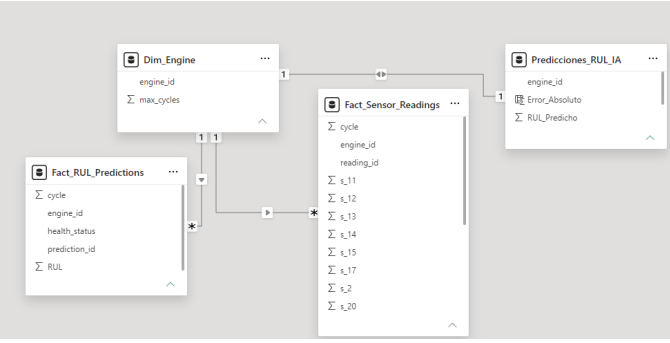


Fig. 1. Modelo Entidad-Relación (DER) en esquema de estrella estructurado en Power BI para el Gemelo Digital.

B. Capa Web Interactiva en Tiempo Real (Streamlit + Plotly)

Para la supervisión operativa detallada a nivel de ingeniería de mantenimiento, se implementó un panel interactivo basado en Python-Streamlit. En la Fig. 2 se presenta la trayectoria de degradación comparativa entre el RUL real y la predicción generada por el algoritmo *Random Forest* para la flota evaluada. La estrecha alineación entre ambas series demuestra la robustez del modelo para capturar la tasa de desgaste en el compresor de alta presión.

Complementariamente, la Fig. 3 ilustra la distribución de frecuencia del error absoluto. La marcada concentración de errores cerca del origen (con la gran mayoría de casos por debajo de 10 ciclos) confirma que la métrica de $MAE \approx 12.09$ es impulsada por pocos casos atípicos extremos, garantizando un pronóstico altamente confiable para la planificación de mantenimiento sin riesgo de fallas imprevistas.

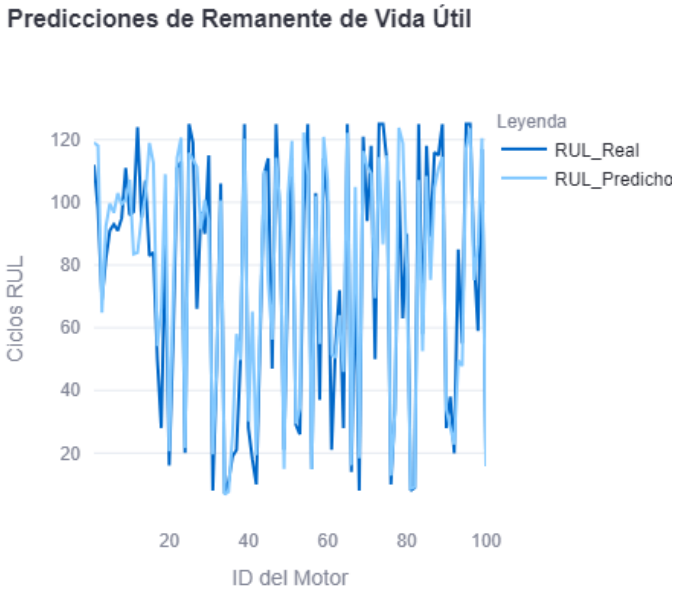


Fig. 2. Trayectoria de degradación comparativa (RUL real vs. RUL predicho) desplegada en la interfaz web de Streamlit.

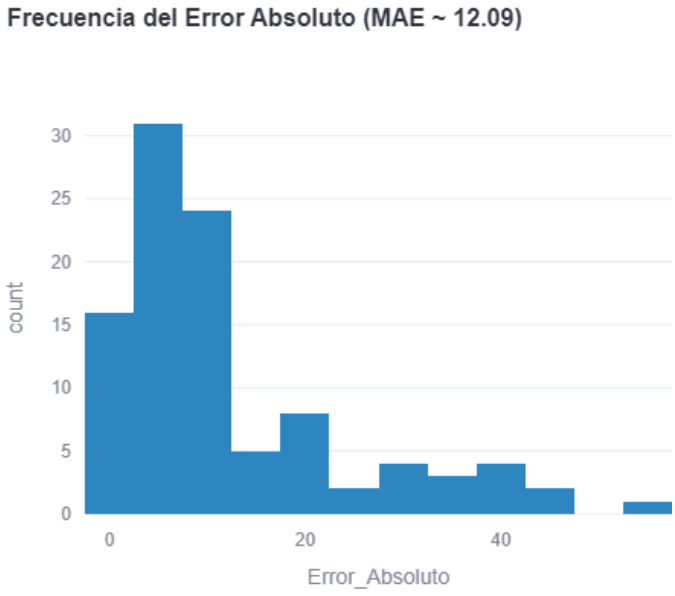


Fig. 3. Distribución de la frecuencia del error absoluto ($MAE \approx 12.09$) generada mediante Plotly.

IV. Conclusiones y Trabajo Futuro

Se desarrolló exitosamente un Gemelo Digital con arquitectura *Dual-Platform* para motores turbofan utilizando el dataset NASA C-MAPSS FD001. El filtrado de varianza nula redujo el espacio telemétrico a 14 sensores clave, y la delimitación de RUL a 125 ciclos optimizó el entrenamiento del algoritmo *Random Forest*, alcanzando métricas competitivas de $RMSE = 17.07$ y $MAE = 12.09$.

La integración funcional de Power BI (para análisis gerencial) y Streamlit (para monitoreo operacional) demuestra que es posible desplegar soluciones de mantenimiento predictivo accesibles, precisas y escalables. Como trabajo futuro, se propone extender la arquitectura hacia arquitecturas de aprendizaje profundo (como redes LSTM o Transformers) e integrar múltiples condiciones de operación y modos de falla (datasets FD002 a FD004).

References

[1] A. Saxena, K. Goebel, D. Simon, and N. Eklund, "Damage propagation modeling for aircraft engine run-to-failure simulation," in *2008 International Conference on Prognostics and Health Management*, 2008, pp. 1–10.

[2] F. Tao, M. Zhang, Y. Liu, and A. Y. C. Nee, "Digital twin driven prognostics and health management for complex equipment," *CIRP Annals*, vol. 68, no. 1, pp. 169–172, 2019.

[3] S. Zheng, S. Riemer, H. Troitzsch, and N. Liu, "Cross-domain remaining useful life prediction for aircraft engines," *IEEE Transactions on Industrial Informatics*, vol. 14, no. 5, pp. 2027–2037, 2018.

[4] F. O. Heimes, "Recurrent neural networks for remaining useful life estimation," pp. 1–6, 2008.

[5] L. Breiman, "Random forests," *Machine learning*, vol. 45, no. 1, pp. 5–32, 2001.