Sustentación Académica y Discurso Técnico: Gemelo Digital Dual-Platform para la Estimación de RUL en Motores Turbofan (NASA C-MAPSS)

Nicolás García García
Facultad de Ingeniería, Pontificia Universidad Javeriana
Bogotá, Colombia

14 de octubre de 2026

Resumen

El presente documento constituye el texto íntegro de la sustentación académica y defensa técnica del proyecto de investigación enfocado en el desarrollo de un Gemelo Digital para la estimación de la Vida Útil Remanente (*Remaining Useful Life*, RUL) en motores turbofan aeronáuticos. Se detalla la fundamentación teórica, el preprocesamiento de series temporales telemétricas del subconjunto NASA C-MAPSS FD001, la arquitectura del modelo predictivo basado en *Random Forest Regressor* ($RMSE = 17{,}07$, $MAE = 12{,}09$ ciclos) y el marco de visualización interactiva Macro/Micro desplegado en la plataforma web Streamlit + Plotly. Asimismo, se expone la interpretación técnica de los indicadores del panel de control, la mecánica del marcador dinámico en estrella y la relevancia de las predicciones conservadoras para el mantenimiento predictivo aeronáutico.

---

1. Introducción y Planteamiento del Problema

El mantenimiento predictivo en la aviación comercial representa uno de los pilares de mayor relevancia técnica y económica en la ingeniería moderna. Las turbomáquinas aeronáuticas operan bajo condiciones térmicas, mecánicas y aerodinámicas extremas, lo que conduce a un desgaste progresivo e inevitable de sus componentes internos, con especial incidencia en el Compresor de Alta Presión (*High-Pressure Compressor*, HPC). Un fallo imprevisto en vuelo no solo implica costos operativos millonarios asociados a paradas no programadas y retrasos logísticos, sino que compromete directamente la seguridad operacional de la aeronave.

En este panorama, la disciplina de Gestión de Salud y Pronóstico (*Prognostics and Health Management*, PHM) ha evolucionado desde esquemas reactivos y preven-

tivos basados en calendario hacia modelos cuantitativos basados en datos telemétricos en tiempo real. La métrica fundamental en PHM es la Vida Útil Remanente (*Remaining Useful Life*, RUL), definida como el número de ciclos operativos o horas de vuelo que le restan a un componente antes de cruzar el umbral crítico de falla funcional.

Este trabajo implementa un Gemelo Digital (*Digital Twin*) sustentado en una arquitectura *Dual-Platform*. Un Gemelo Digital es la representación virtual, dinámica y sincronizada de un activo físico. Para el desarrollo de esta investigación se empleó el dataset público C-MAPSS (*Commercial Modular Aero-Propulsion System Simulation*) proporcionado por el Centro de Investigación Ames de la NASA, específicamente el subconjunto FD001, el cual simula la degradación de una flota de 100 motores turbofan operando bajo condiciones ambientales constantes y un modo de falla único en el HPC.

2. Preprocesamiento MLOps y Arquitectura Predictiva

El conjunto de datos C-MAPSS recopila la lectura de 21 sensores telemétricos a lo largo del tiempo (temperaturas, presiones, velocidades de rotación, flujos de combustible, entre otros). Para garantizar la calidad del modelo de Machine Learning y evitar el sobreajuste (*overfitting*), se aplicó un protocolo riguroso de ingeniería de características:

2.1. Filtrado de Sensores sin Varianza

Un análisis de varianza nula reveló que los sensores $S_1, S_5, S_6, S_{10}, S_{16}, S_{18}$ y S_{19} mantuvieron lecturas completamente constantes ($\sigma = 0$) a lo largo de todas las series temporales de la flota. Dado que las variables con varianza nula no aportan capacidad discriminativa ni información sobre la progresión del desgaste, fueron eliminadas del espacio de entrada, reduciendo la dimensión del problema de 21 a 14 sensores activos.

2.2. Delimitación Tramo de la Variable Objetivo (RUL_{max})

Durante las primeras etapas de operación de una turbomáquina, el estado físico del motor se mantiene óptimo y no registra degradación apreciable. Entrenar un modelo de aprendizaje supervisado para predecir valores arbitrariamente altos de RUL en etapas tempranas induce ruido y deteriora la precisión en la fase crítica final. Siguiendo la literatura especializada en diagnóstico de turbomáquinas, se fijó un umbral tramo de $RUL_{max} = 125$ ciclos. Cualquier valor real de vida útil superior a 125 ciclos fue truncado a dicho límite, permitiendo que el algoritmo concentre su capacidad predictiva en la ventana operacional donde la falla se encuentra más próxima.

2.3. Evaluación del Modelo Random Forest Regressor

Se entrenó un algoritmo de regresión basado en *Random Forest Regressor*, seleccionado por su capacidad inherente para capturar interacciones no lineales entre

sensores telemétricos y su robustez frente al ruido. La optimización del modelo se midió sobre el conjunto de prueba independiente (100 motores), alcanzando un Error Cuadrático Medio ($RMSE$) de 17,07 y un Error Absoluto Medio (MAE) de 12,09 ciclos de operación.

3. El Framework de Visualización Macro/Micro

La principal contribución práctica de esta investigación reside en la traducción de un modelo analítico de Inteligencia Artificial en una herramienta interactiva de soporte a la decisión para ingenieros de mantenimiento. Esto se logró a través de una interfaz web desarrollada en Python con Streamlit y Plotly, estructurada bajo el principio de diseño de visualización *Macro/Micro*.

3.1. Perspectiva Macro: Evaluación Global MLOps (Histograma)

La gráfica ubicada en la columna derecha de la interfaz web representa la perspectiva **Macro**. Corresponde a un histograma de frecuencia de distribución del Error Absoluto ($|RUL_{real} - RUL_{pred}|$) para la totalidad de la flota.

Desde el punto de vista de validación de modelos de IA, este gráfico permite responder a la pregunta: *¿Es el modelo estadísticamente confiable para toda la flota?* La distribución exhibe un sesgo positivo hacia la izquierda, donde la mayor concentración de barras se ubica en el intervalo de 0 a 10 ciclos de error. Esto demuestra que la métrica global de $MAE \approx 12{,}09$ está influenciada por un número reducido de casos atípicos extremos, mientras que para la abrumadora mayoría de las aeronaves el pronóstico se realiza con un margen de error mínimo.

3.2. Perspectiva Micro: Diagnóstico Individualizado y Marcador Dinámico

La columna izquierda y el gráfico de líneas representan la perspectiva **Micro**. Mientras que la vista macro analiza la flota en su conjunto, la vista micro permite aislar la salud telemétrica de un motor específico (del 1 al 100) mediante el selector interactivo.

El elemento central de esta vista es el marcador en **estrella roja de gran tamaño**, el cual opera como una ”mira telescópica”dinámica sobre la trayectoria global de la flota:

- **Desplazamiento Horizontal (Eje X):** Representa el identificador único del motor (ID $= 1 \dots 100$). Al cambiar el motor en el selector, la estrella se desplaza horizontalmente posicionándose de forma exacta sobre la coordenada de la unidad seleccionada.
- **Desplazamiento Vertical (Eje Y):** Representa el valor exacto de la Vida Útil Remanente predicha (RUL_{pred}) por la Inteligencia Artificial para ese motor específico.

Esta doble articulación permite que el operador identifique instantáneamente el nivel de desgaste del motor seleccionado en relación con la tendencia general de los demás motores de la flota.

4. Análisis de Caso e Indicadores del Panel de Control

Para ilustrar el funcionamiento operativo del Gemelo Digital, consideremos la inspección del **Motor #100** en el panel de control:

1. **RUL Real (20 ciclos):** Indica que, de acuerdo con el historial telemétrico de la NASA, al motor #100 le restaban 20 ciclos operativos antes de la falla.

2. **RUL Predicho (15 ciclos):** Muestra el cálculo estimado por el modelo de Random Forest.

3. **Delta de Error (-4 ciclos / conservador):** El modelo estimó que al motor le quedaban 15 ciclos cuando en realidad le quedaban 20. En ingeniería de mantenimiento aeronáutico, un error por subestimación (conservador) es sumamente deseable, ya que alerta al equipo de mantenimiento con 4 ciclos de anticipación, programando la inspección preventiva antes de que el activo entre en zona de riesgo real de falla catastrófica.

4. **Error Absoluto (4,20 ciclos):** Es la diferencia absoluta directa ($|20 - 15{,}8| = 4{,}20$), confirmando que para esta unidad la precisión fue excepcionalmente alta, ubicando al Motor #100 dentro del bloque de mayor exactitud del histograma macro.

5. Conclusiones

El Gemelo Digital desarrollado por Nicolás García García demuestra con rigor técnico e innovación práctica cómo articular algoritmos de Machine Learning con arquitecturas de visualización modernas. La combinación de la capa analítica estratégica en Power BI y la capa operativa interactiva en Streamlit responde con exactitud a las exigencias operativas de la industria aeronáutica moderna. La validación de la "Prueba de Cero"garantiza la reproducibilidad y estabilidad del software para su presentación e implementación académica en la Pontificia Universidad Javeriana.